

אני מבקש ממך לבצע עבורי משימת הכנה טכנית וממוקדת: סינון ומיון של פסוקים מקראיים, כקלט למחקר לשוני שיתבצע אחר כך session נפרד.
זו אינה משימת מחקר. אל תנתח את המילה - רק מייך וסנן.

הרקע: למה צריך את השלב הזה

אני מבצע מחקרים לשוניים על מילים מקראיות.
הסשן הראשי מקבל את המופעים של המילה בתנ"ך, עובר על כל פסוק ובוחר מה הוא מלמד על המילה.
הבעיה: לחלק מהמילים יש מאות מופעים. הגשה של כולם מעמיסה על ה-context-window של הסשן הראשי, ופוגעת באיכות המחקר.
הפתרון: session מקדים (זה שלך) שמצמצם את הרשימה לגודל סביר - בלי לאבד את הגיוון.

העיקרון המנחה: לא לחשוב במקום הסשן הראשי

בפעמים קודמות, שלב ההכנה היה opinionated: הוא כבר ביצע ניתוח לשוני בסיסי.
הוא הציע משמעות יסודית, סידר את הקבוצות לפי השערה, נתן לקבוצות שמות פרשניים ("נפש = חיים"), והוסיף שאלות מחקר.
זה מזיק: הסשן הראשי מקבל את "המחשבות הראשוניות" האלה, ונוטה לאמץ אותן (anchoring) במקום להגיע למסקנות בעצמו.
המחקר הלשוני, על כל שלביו, שייך לסשן הראשי. תפקידך הוא רק להגיש לו חומר גלם מסונן ומאורגן.

מכאן - ההבחנה בין מה שמותר למה שאסור:

מותר (ונדרש):

- מיון לפי Strong's number.
- מיון לפי הקשר לשוני נצפה: צירופים קבועים (collocations), נוסחאות חוזרות, תפקיד תחבירי (נושא, מושא, סמיכות, מילת יחס), בניין, צורה דקדוקית, פעלים ושמות שמופיעים לצד המילה, מקבילות בתקבולת.
- שם קצר לכל קבוצה, שמתאר את ההקשר הנצפה - למשל: "מושא של ב.ק.ש: 'מבקשי נפשי'", "בצירוף 'נפש חיה'", "אחרי שם מספר", "נפעל".
- ספירות: כמה פסוקים יש לכל קבוצה, וכמה נבחרו.

אסור:

- להציע משמעות - לא לקבוצה, לא לפסוק ולא למילה ("כאן X פירושו Y").
- שמות קבוצות פרשניים ("X כרגש", "X במובן מופשט").
- הסברים או הערות על מה שהפסוקים מלמדים.
- אטימולוגיה, השוואה ללשונות שמיות, הפניות למחקר או למילונים.
- השערות על משמעות ראשונית או על כיוון התפתחות, וסידור הקבוצות לפי השערה כזאת.
- שאלות מחקר, "נקודות מעניינות", או סיכומים.

כשיש ספק אם משהו הוא תיאור או פרשנות - החלט לטובת תיאור יבש, או השמט.

הקלט

אני אספק לך של תיקיה שנמצאת תחת איסוף-מקדים-לניתוחים-לשוניים/ - בדרך כלל שורש עברי.

וודא שהקובץ איסוף-מקדים-לניתוחים-לשוניים/שורש/פסוקים-גולמיים.rtl.md קיים.

קרא את הקובץ כולו - אם הוא ארוך, בחלקים. אל תסתפק בדגימה: השיוך לקבוצות חייב לכסות את כל הפסוקים.

הרשימה מחולקת לבלוקים לפי Strong's number. כל בלוק נפתח בשורת כותרת, ואחריה פסוק בכל שורה - בסדר הספרים בתנ"ך:

H3513 = קָבַד (פֶּעַל)

וַיֹּאמֶר יְהוָה זַעֲקֵת סֹדִם וְעֲמָרָה כִּי רָבָה וְחֲטָאתָם כִּי קָבַדָּה מְאֹד (בראשית יח:כ)

... (...)

H7045 = קָלְלָה (שֵׁם עֶצֶם)

... (...)

המשימה

1. חלוקה ראשית לפי Strong's number - כל Strong's number נשאר בלוק נפרד, עם שורת הכותרת המקורית שלו.

2. קיבוץ לפי הקשר לשוני (שלב פנימי - עוד לפני הצמצום) - בתוך כל בלוק, שייך כל פסוק מהקלט לקבוצה. השיוך הזה הוא ממצה, והוא נועד רק לספירה: הוא מה שמאפשר לכתוב ליד כל קבוצה כמה פסוקים יש לה בקלט כולו - כדי שהסשן הראשי יידע עד כמה ההקשר דומיננטי, גם כשנבחרו ממנו רק נציגים. רוב הפסוקים המשויכים לא ייכנסו לקובץ הפלט - הצמצום עצמו מתבצע בסעיף 3.

בדרך כלל פסוק שייך לקבוצה אחת. אבל פסוק עשוי להופיע בשתי קבוצות אם יש צורך - למשל כשהמילה מופיעה בו פעמיים בהקשרים שונים, או כשהוא מדגים שני הקשרים באותה מידה. אל תשכפל פסוקים סתם. מופעים שאינם מתאימים לאף הקשר חוזר - קבוצת "צירופים יחידאיים ואחרים". אל תפצל יותר מדי: קבוצה של מופע אחד מוצדקת רק כשההקשר באמת יחידאי.

3. **בחירה** - מכל קבוצה, בחר את הפסוקים שיעברו לסשן הראשי:

- Strong's number עם מעט מופעים (עד כ-30) - נשאר **במלואו**. הצמצום נועד לבלוקים הגדולים בלבד.
 - קבוצה קטנה - נשארת במלואה או כמעט במלואה.
 - קבוצה נוסחתית גדולה (אותו צירוף שחוזר עשרות פעמים) - מספיקים כמה נציגים (בערך 4-6). מעבר לזה הם לא מוסיפים מידע.
 - בבחירת נציגים: העדף פסוקים מחמשת החומשים (המחקר ממוקד בתורה), ואחר כך פיזור בין ספרים וסוגות (חוק, סיפור, שירה, נבואה, חכמה).
 - שמור תמיד את המופעים החריגים - אלה שההקשר שלהם שונה מהרגיל או שאינם מתיישבים בקלות עם שאר המופעים. אל תבחר נציגים "נקיים" בלבד.
 - אל תהיה סלקטיבי מדי: בחירה של מעט מדי פסוקים היא counter-productive. המטרה היא להוריד חזרות, לא לגוון פחות.
 - קנה מידה: פסוק מנוקד עולה בממוצע כ-100 טוקנים. יעד של **עד כ-300 פסוקים בסך הכול** (כ-30,000 טוקנים) - לא מספר קשיח, אבל חריגה משמעותית צריכה הצדקה.
4. **העתקה מדויקת** - העתק את שורות הפסוקים **כלשונן** מהקלט, כולל הניקוד וההפניה. אל תקליד מחדש, אל תתקן ואל תקצר. הדרך הבטוחה: לחלץ את השורות מהקלט בעזרת סקריפט (Python) ולא לכתוב אותן בעצמך - הקלדה מחדש של ניקוד עלולה לשבש אותן.
- בתוך כל קבוצה - שמור על סדר הפסוקים כמו בקלט.
5. **בדיקה עצמית** - לפני כתיבת הקובץ, ודא (עם סקריפט) ש:
- הספירות נכונות: כל שורת פסוק של הבלוק בקלט נספרה בקבוצה אחת לפחות (כלומר אף פסוק לא "נפל" מהספירה - גם אם לא נבחר לפלט), ומספר הפסוקים שבכותרת הבלוק שווה למספר השורות שלו בקלט.
 - כל שורת פסוק בקובץ הפלט זהה ביט-ביט לשורה בקלט.

הפלט

קובץ **אחד**, באותה תיקיה של קובץ הקלט: **איסוף-מקדים-לניתוחים-לשוניים/שורש>/פסוקים-נבחרים.rtl.md**
אל תשנה את קובץ הקלט, ואל תיצור קבצים נוספים (סקריפטי עזר - רק בתיקה זמנית מחוץ לפרויקט).

הסשן הראשי של הניתוח הלשוני יקבל את הקובץ **פסוקים-נבחרים.rtl.md** כקלט. לכן הוא צריך להכיל רק את רשימת הפסוקים המאורגנת - ושום דבר מעבר לזה.
מבנה הקובץ:

נִפְשׁ (פֻּעַל) [3 פסוקים - כולם נבחרו] H5314 =

ִּ...ִּ (...)

ִּ...ִּ (...)

ִּ...ִּ (...)

נִפְשׁ (שֵׁם עָצָם) [683 פסוקים - נבחרו 280] H5315 =

בצירוף "נפש חיה" [14 <- 14]

ִּ...ִּ (...)

ִּ...ִּ (...)

מושא של ב.ק.ש: "מבקשי נפשי" [6 <- 54]

ִּ...ִּ (...)

...

- שורת הכותרת של כל Strong's number - כמו בקלט, ואחריה ספירה: כמה פסוקים בקלט, וכמה נבחרו.
- שורת הכותרת של כל קבוצה - שם תיאורי קצר (שורה אחת), ואחריו [סך הפסוקים בקבוצה <- כמה נבחרו].
- פסוק שהופיע בשתי קבוצות - סמן אותו בשתייהן בסוף השורה: (גם בקבוצה: <שם הקבוצה האחרת>).
- סדר הקבוצות בתוך בלוק - לפי המופע הראשון של כל קבוצה בסדר הספרים (סדר ניטרלי, שאינו משקף השערה).
- בלי מבוא, בלי טבלת סיכום, בלי הערות מתודולוגיות, ובלי סיכום בסוף.

בסיום:

- כתוב את הקובץ.
- דווח לי בקצרה (בצ'אט - לא בקובץ): כמה פסוקים היו בכל Strong's number, כמה נבחרו, כמה קבוצות נוצרו, וכמה פסוקים הופיעו בשתי קבוצות.
- אם התלבטת בשיוך של מופעים מסוימים, או שיש מופעים בקלט שנראים שגויים (למשל: המילה לא מופיעה בפסוק) - ציין אותם בצ'אט.
- אל תתחיל את המחקר עצמו.